



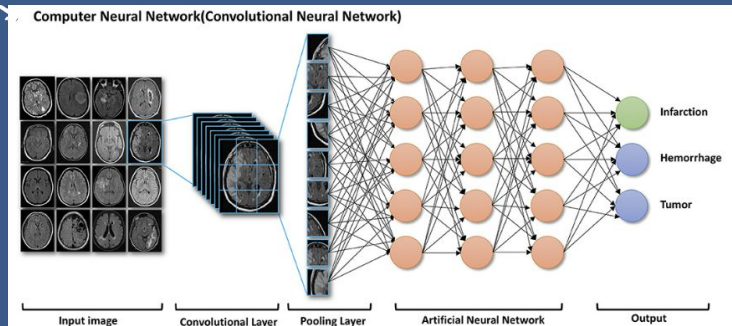
UNIVERSIDAD
NACIONAL
DE COLOMBIA

Convolutional Neural Networks: An overview in radiology

Proyecto final Análisis numérico

Integrantes:

Ahumada Lozano, Santiago
Arevalo Gomez, Juan Esteban
Salamanca Lozano, Juan Felipe



Gran parte del desarrollo tecnológico en la visión por ordenador se debe a las redes neuronales convolucionales por su potencial computacional.


Algunas referencias que consideramos, nos serán útiles en el desarrollo del proyecto son:


- [1]Dähnert, W., n.d. *Radiology review manual*.
- [2]Venkatesan, R. and Li, B., n.d. *Convolutional neural networks in visual computing*.
- [3]Sewak, M., Karim, R. and Pujari, P., n.d. *Practical convolutional neural networks*.
- [4]Yamashita, R., Nishio, M., Do, R. and Togashi, K., n.d. *Convolutional neural networks: an overview and application in radiology*.

Para el proyecto de Análisis numérico (2022-1S) hemos optado por investigar sobre las redes neuronales convolucionales (CNN, por sus siglas en inglés). La elección de este proyecto se dió gracias a una interesante aplicación que encontramos en radiología.

Los integrantes del grupo tenemos nociones esenciales sobre el aprendizaje automatizado y conocemos el poder de las CNN en cuanto a problemas de clasificación de imágenes.

Entre otros datos de interés, nos hemos topado con que este tipo de red neuronal es relativamente moderno puesto que apenas en el año 1989, el informático Yann LeCun, introdujo el primer diseño de una CNN utilizada para reconocer los dígitos de cheques bancarios.





Cuya implementación técnica puede ser apoyada con el uso de diversas herramientas tanto de python como de julia



Para la relación del proyecto con las herramientas aprendidas en el curso de análisis numérico. Hemos encontrado algunos algoritmos de optimización como

Gradient Descent (G.D.) $\theta_{n+1} = \theta_n - \alpha \cdot \nabla J(\theta_n)$

Mini-Batch G.D. $\theta = \theta - \alpha \cdot \nabla J(\theta; B(i))$

Momentum $V(t) = \gamma V(t-1) + \alpha \cdot \nabla J(\theta)$

Adagrad $g_{t,i} = \nabla_{\theta} J(\theta_{t,i})$

Entre otros como AdaDelta, Adam, etc.



REVIEW



Convolutional neural networks: an overview and application in radiology

Rikiya Yamashita^{1,2} · Mizuho Nishio^{1,3} · Richard Kinh Gian Do² · Kaori Togashi¹

Received: 3 March 2018 / Revised: 24 April 2018 / Accepted: 28 May 2018 / Published online: 22 June 2018
© The Author(s) 2018

Abstract

Convolutional neural network (CNN), a class of artificial neural networks that has become dominant in various computer vision tasks, is attracting interest across a variety of domains, including radiology. CNN is designed to automatically and adaptively learn spatial hierarchies of features through backpropagation by using multiple building blocks, such as convolution layers, pooling layers, and fully connected layers. This review article offers a perspective on the basic concepts of CNN and its application to various radiological tasks, and discusses its challenges and future directions in the field of radiology. Two challenges in applying CNN to radiological tasks, small dataset and overfitting, will also be covered in this article, as well as techniques to minimize them. Being familiar with the concepts and advantages, as well as limitations, of CNN is essential to leverage its potential in diagnostic radiology, with the goal of augmenting the performance of radiologists and improving patient care.

También se encontró información sobre redes neuronales intervalares, las cuales realizan sus procesamientos haciendo uso de Aritmética Intervalar. Esto beneficia el proceso ya que arroja más información sobre el intervalo de error [5].



Otras referencias sobre CNNs, Redes Neuronales Intervalares y Análisis Intervalar incluyen:

- [1] Krishna, R. (2017). Computer vision: Foundations and applications. Reference Book, 213.
- [2] Moore, R. E., Kearfott, R. B., y Cloud, M. J. (2009). Introduction to interval Analysis. SIAM.
- [3] Wu, J. (2017). Introduction to convolutional neural networks. National Key Lab for Novel Software Technology. Nanjing University. China, 5(23), 495.
- [4] Yamashita, R., Nishio, M., Do, R. K. G., y Togashi, K. (2018). Convolutional neural networks: an overview and application in radiology. Insights into imaging, 9(4), 611–629.
- [5] Oala, L., Heiß, C., Macdonald, J., März, M., Samek, W., y Kutyniok, G. (2020). Interval neural networks: Uncertainty scores. arXiv preprint arXiv:2003.11566.

El documento que inspiró este trabajo es un paper sobre redes neuronales de convolución (CNN) y su aplicación en el campo de la radiología [4]. En este se explica el funcionamiento de dicho tipo de redes neuronales y se ilustran ejemplos de imágenes procesadas por esta CNN. También destaca la importancia de la optimización en ciertos pasos de su procesamiento y las técnicas utilizadas para esto.


INTERVAL NEURAL NETWORKS: UNCERTAINTY SCORES

LUIS OALA^{*1}, COSMAS HEISS^{*2}, JAN MACDONALD², MAXIMILIAN MÄRZ²,
WOJCIECH SAMEK¹, AND GITTA KUTYNIOK²

ABSTRACT. We propose a fast, non-Bayesian method for producing uncertainty scores in the output of pre-trained deep neural networks (DNNs) using a data-driven interval propagating network. This interval neural network (INN) has interval valued parameters and propagates its input using interval arithmetic. The INN produces sensible lower and upper bounds encompassing the ground truth. We provide theoretical justification for the validity of these bounds. Furthermore, its asymmetric uncertainty scores offer additional, directional information beyond what Gaussian-based, symmetric variance estimation can provide. We find that noise in the data is adequately captured by the intervals produced with our method. In numerical experiments on an image reconstruction task, we demonstrate the practical utility of INNs as a proxy for the prediction error in comparison to two state-of-the-art uncertainty quantification methods. In summary, INNs produce fast, theoretically justified uncertainty scores for DNNs that are easy to interpret, come with added information and pose as improved error proxies - features that may prove useful in advancing the usability of DNNs especially in sensitive applications such as health care.



Introduction to **INTERVAL ANALYSIS**



Ramon E. Moore
R. Baker Kearfott
Michael J. Cloud

Para el desarrollo de la parte del trabajo sobre Aritmética Intervalar y su aplicación en redes neuronales intervalares se seguirá el libro de Introduction to Intervalar Analysis de Moore, Kearfott y Cloud, entre otras referencias.

La idea detrás a la Aritmética Intervalar es realizar operaciones usando intervalos, esto con el propósito de dar cotas de error para los resultados. Por ejemplo si se mide cierto parámetro con cierta precisión tal que el valor exacto está en un intervalo real $[a,b]$, entonces si se desea realizar cierta aritmética con el valor exacto, basta con usar el intervalo encontrado y sus límites para encontrar otro intervalo donde el valor modificado se encontrará. Un estudio detallado de esta aritmética puede ayudar a reducir las cotas de error de los valores deseados.

Este libro también da ciertas aplicaciones de esta aritmética como por ejemplo:

- Pruebas Asistidas por Computador
- Aplicaciones en Robótica
- Graficación con Computador
- Computación de Constantes Físicas





Para la parte computacional del proyecto aplicaremos las ideas de procesamiento de imágenes vistas en el artículo, para esto usaremos julia, más específicamente los paquetes incluidos en el ecosistema **JuliaImages**, tales como:



Low-level core packages (para empezar, posiblemente usando otros posteriormente):

ColorTypes.jl, **Colors.jl** y **ColorVectorSpace.jl** proveen definiciones y funciones de nivel de píxeles.

FixedPointNumbers.jl provee varios tipos de datos (e.g., `Nof8`) para uso en almacenamiento de imágenes.

ImageCore.jl provee atributos y funciones básicas y convenientes para soportar algoritmos de procesamiento de imágenes.

